Juan Menduiña

Trabajo Práctico N° 6

Chapter 6
The Memory Hierarchy

To this point in our study of systems, we have relied on a simple model of a computer system as a CPU that executes instructions and a memory system that holds instructions and data for the CPU. In our simple model, the memory system is a linear array of bytes, and the CPU can access each memory location in a constant amount of time. While this is an effective model as far as it goes, it does not reflect the way that modern systems really work.

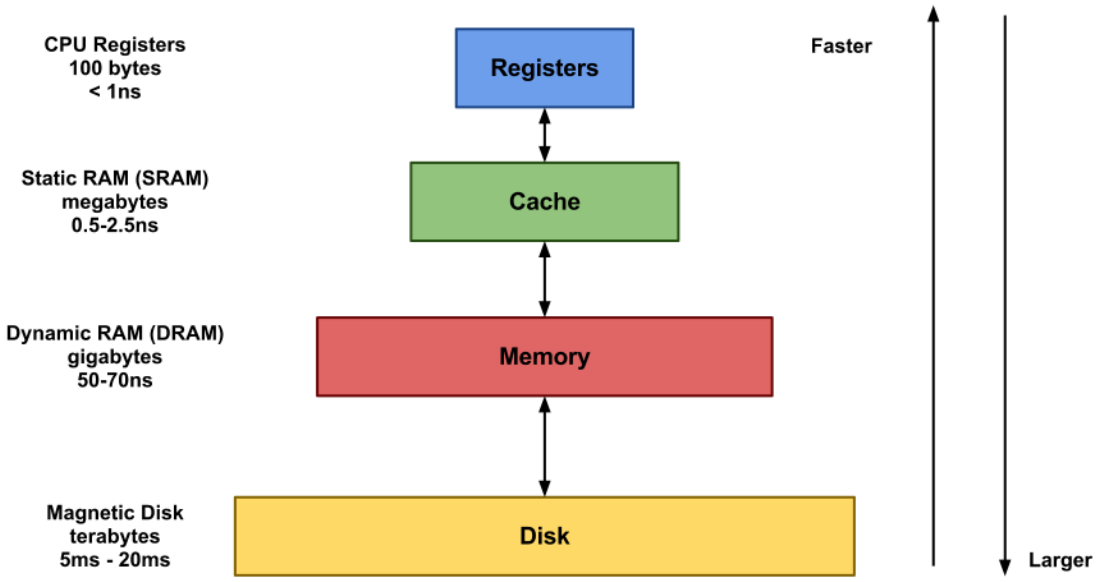
In practice, a memory system is a hierarchy of storage devices with different capacities, costs, and access times. CPU registers hold the most frequently used data. Small, fast *cache memories* nearby the CPU act as staging areas for a subset of the data and instructions stored in the relatively slow main memory. The main memory stages data stored on large, slow disks, which in turn often serve as staging areas for data stored on the disks or tapes of other machines connected by networks.

Memory hierarchies work because well-written programs tend to access the storage at any particular level more frequently than they access the storage at the next lower level. So the storage at the next level can be slower, and thus larger and cheaper per bit. The overall effect is a large pool of memory that costs as much as the cheap storage near the bottom of the hierarchy, but that serves data to programs at the rate of the fast storage near the top of the hierarchy.

As a programmer, you need to understand the memory hierarchy because it has a big impact on the performance of your applications. If the data your program needs are stored in a CPU register, then they can be accessed in zero cycles during the execution of the instruction. If stored in a cache, 1 to 30 cycles. If stored in main memory, 50 to 200 cycles. And if stored in disk tens of millions of cycles!

Here, then, is a fundamental and enduring idea in computer systems: If you understand how the system moves data up and down the memory hierarchy, then you can write your application programs so that their data items are stored higher in the hierarchy, where the CPU can access them more quickly.

This idea centers around a fundamental property of computer programs known as locality. Programs with good locality tend to access the same set of data items over and over again, or they tend to access sets of nearby data items. Programs with good locality tend to access more data items from the upper levels of the memory hierarchy than programs with poor locality, and thus run faster. For example, the running times of different matrix multiplication kernels that perform the same number of arithmetic operations, but have different degrees of locality, can vary by a factor of 20!



It can be noted that the larger the memory, the slower the data access.

6.1 Storage Technologies

Much of the success of computer technology stems from the tremendous progress in storage technology. Early computers had a few kilobytes of random-access memory. The earliest IBM PCs did not even have a hard disk. **That** changed with the introduction of the IBM PC-XT in 1982, with its 10-megabyte disk. By the year 2010, typical machines had 150,000 times as much disk storage, and the amount of storage was increasing by a factor of 2 every couple of years.
Glosario: To stage: *montar / manipular*

Ejercicio 1.

(a) *Leer el texto completo con atención e indicar en qué párrafo se mencionan las siguientes ideas (Parte 6):*

- Ciclos requeridos para acceder a la información - Párrafo 4.
- Rol de la memoria principal - Párrafo 2.
- Importancia de la localidad - Párrafo 6.

(b) *Marcar con un tilde los conceptos que están definidos en el texto.*

- ***Computer system***
- ***Memory system***
- ***Caché memory***
- ***Locality***
- Storage devices

Ejercicio 2.

Leer el texto, nuevamente, y decidor si las siguientes afirmaciones son correctas:

a. Toda la información que es, frecuentemente, usada se encuentra en los registros de la CPU. SI / ***NO***
b. La primera computadora personal IBM consistía en un disco duro. SI / ***NO***
c. Para acceder a los datos almacenados en un disco, se necesitan más de un millón de ciclos. ***SI*** / NO
d. Un programador debe estar familiarizado con la jerarquía de memoria. ***SI*** / NO
e. Los adelantos en la tecnología de almacenamiento han beneficiado el desarrollo de la tecnología de las computadoras. ***SI*** / NO

Ejercicio 3.

Encerrar, en un círculo, a qué refieren las palabras resaltadas en el texto.

It	CPU / ***model***
they	hierarchies / ***programs***
their	application programs / ***data items***
them	application programs / ***data items***
That	a few kilobytes of … memory / ***The earliest IBM PCs did not … a disk***

Ejercicio 4.

Las expresiones subrayadas a lo largo del texto tienen en común que expresan: ***comparación***.

(a) *¿Se podrían agrupar?*

- Comparación de adjetivos: larger, cheaper, faster, slower.
- Comparación de adverbios: more quickly, more frequently.
- Adjetivos superlativos: the most frequently used, the largest, the fastest.
- Otras formas de comparación: as far as, more than, less than.

(b) *Ahora, traducir las frases completas al español.*

1. the most frequently used data -
los datos utilizados con mayor frecuencia.

2. programs tend to access the storage at any particular level more frequently than … -
los programas tienden a acceder al almacenamiento en un nivel determinado con mayor frecuencia que …

3. the next lower level -
el siguiente nivel inferior.

4. the storage at the next level can be slower, and thus larger and cheaper per bit … -
el almacenamiento en el siguiente nivel puede ser más lento y, por lo tanto, de mayor capacidad y más barato por bit …

5. their data items are stored higher in the hierarchy -
sus elementos de datos se almacenan en niveles superiores de la jerarquía.

6. the CPU can access them more quickly -
la CPU puede acceder a ellos más rápidamente.

7. Programs with good locality tend to access more data* items from the upper levels of the memory hierarchy than programs with poor locality, and thus run faster -
Los programas con buena localidad tienden a acceder a más elementos de datos de los niveles superiores de la jerarquía de memoria que los programas con mala localidad y, por lo tanto, se ejecutan más rápidamente.

8. The earliest IBM PCs -
Las primeras PC de IBM.

(c) *¿Qué indica more en more data *? ¿Qué valor tiene?*

Indica que se accede a una cantidad mayor de elementos de datos.

Ejercicio 5.

Completar, brevemente, con información del texto:

(a) En la actualidad, la manera en que funcionan los sistemas modernos no ***se parece al modelo simple de una CPU y una memoria única***.

(b) Los programas con buena localidad son más rápidos debido a que ***acceden a más datos desde los niveles superiores de la jerarquía de memoria***.

(c) A partir de 1982, con la PC de IBM ***se incorporó el disco duro, aumentando considerablemente la capacidad de almacenamiento.***

Ejercicio 6.

¿Causa o consecuencia? Completar las oraciones de la grilla con información del texto. Luego, analizar:

Causa	Consecuencia
Si la información está guardada en un registro de la CPU,	puede acceder a la información en tus programas sin usar ciclos.
Si la información está guardada en la caché,	necesitará de a 1 a 30 ciclos.
Si la información está guardada en la memoria principal,	entonces, ***necesitará de 50 a 200 ciclos.***
Si la información está guardada en el disco,	***necesitará decenas de*** millones de ciclos

Ejercicio 7.

Observar, nuevamente, la figura:

(a) *¿Es posible comprender la figura sin leer el texto?*

Sí, pero sólo parcialmente. La figura permite identificar los diferentes niveles de la jerarquía de memoria y observar que, a medida que se sube en la pirámide, la memoria es más rápida y de menor capacidad. Sin embargo, para comprender, completamente, la relación entre los niveles y su funcionamiento, es necesario leer el texto.

(b) *Explicar qué información suministra la pirámide.*

La pirámide muestra los distintos niveles de la jerarquía de memoria, desde los registros hasta el disco:

- Registros: menor capacidad y mayor velocidad.
- Caché: más capacidad que los registros, pero más lenta.
- Memoria principal: mayor capacidad y menor velocidad que la caché.
- Disco: mayor capacidad, pero es el nivel más lento.

Además, las flechas indican que hacia arriba aumenta la velocidad (faster) y hacia abajo aumenta la capacidad (larger).